

확률통계 · 실험계획법

핵심 개념 요약정리

이 자료는 통계를 처음 공부하는 분이 '어떤 개념을, 어떤 상황에서 쓰는가'를 한눈에 잡을 수 있도록 정리한 학습 노트입니다. 어려운 수식은 최소화하고, **전자·반도체·메모리 공장**의 친숙한 장면에 빔대어 설명했습니다. 특히 시험에서 자주 헛갈리는 네 가지 '종류' — **분산의 종류, 가설 검정의 종류, 분산 분석의 종류, 상관 분석의 종류** — 는 별도로 표와 비유를 붙여 꼼꼼하게 다룹니다.

□ 이 자료를 읽는 법

- 각 장(章)은 책의 목차 순서를 그대로 따릅니다. 앞에서부터 천천히 읽으세요.
- 노란 박스(□ 쉽게 이해하기)는 어려운 용어를 일상 장면에 빔댄 비유입니다.
- 파란 박스(✓ 꼭 기억하기)는 시험 직전에 다시 볼 핵심 한 줄 정리입니다.
- 표는 '비슷해서 헛갈리는 것들'을 한 번에 비교하기 위한 것입니다.

0. 시작하기 전에 — 통계를 '반도체 공장'으로 이해하기

본격적인 개념에 들어가기 전에, 이 책 전체를 관통하는 큰 그림을 하나의 비유로 잡아 두면 훨씬 쉽습니다. 통계와 실험계획법은 결국 '**들쭉날쭉한 현실 속에서 진짜 신호를 찾아내는 기술**'입니다.

□ 쉽게 이해하기 — 메모리 칩 공장 이야기

메모리 칩을 만드는 공장을 상상해 봅시다. 똑같은 설비로 똑같이 만들어도 칩마다 속도·전압·수명이 조금씩 다릅니다. 이 '조금씩 다름'이 바로 **변동(variation)** 이고, 통계의 출발점입니다.

- **확률**: 다음에 뽑은 칩이 불량일 '가능성'을 숫자로 표현 → 2 장
- **통계량(평균·분산)**: 수천 개 칩의 성능을 요약하는 대표 숫자 → 3 장

- **확률 분포**: 칩 속도가 어떤 모양으로 퍼져 있는지의 '지도' → 4·5·6 장
- **가설 검정**: '새 공정이 정말 더 좋아졌나?'를 데이터로 판정 → 7 장
- **회귀·상관**: '전압을 높이면 속도가 빨라지나?' 관계를 분석 → 8·10 장
- **분산 분석(ANOVA)**: 'A·B·C 세 라인의 수율이 같은가?' 동시 비교 → 9 장
- **실험계획법(DOE)**: '최소 실험으로 최적 공정을 찾는' 똑똑한 실험 설계 → 11~15 장

2 장. 확률 기초 — 확률을 바라보는 세 가지 관점

2-1. 확률이란 무엇인가

확률(Probability) 은 어떤 사건이 일어날 가능성을 **0 과 1 사이의 숫자**로 나타낸 것입니다. 0 이면 절대 안 일어남, 1 이면 반드시 일어남, 0.5 면 반반입니다.

2-2. 확률을 해석하는 세 가지 관점 ★

같은 '확률'이라는 말도 누가, 어떤 상황에서 쓰느냐에 따라 의미가 조금씩 다릅니다. 크게 세 가지로 나뉩니다.

관점	확률을 정하는 방식	어떤 상황에서 쓰나	한 줄 예시
고전적(수학적) 해석	모든 경우가 똑같이 일어난다고 보고 '경우의 수 비율'로 계산	주사위·동전처럼 결과가 균등한 실험	주사위 짝수 = $3/6 = 1/2$
빈도적(통계적) 해석	실험을 무한히 반복 했을 때 나타나는 상대 빈도의 극한	반복 실험·관측 데이터	동전 1 만 번 던져 앞면 비율 ≈ 0.5
주관적(베이지안) 해석	개인의 사전 지식·믿음의 정도	딱 한 번뿐인 사건	'이 팀이 우승할 확률 60%'

□ 쉽게 이해하기 — 불량률을 말하는 세 사람

반도체 라인의 '불량 확률'을 세 사람이 말합니다.

- **고전적**: '이론상 8 가지 결과 중 1 가지가 불량이니 $1/8$ 이야' (이상적인 계산).
- **빈도적**: '지난 10 만 개 중 1,200 개가 불량이었으니 약 1.2%야' (반복 관측). 횟수가 많아질수록 관측 비율이 참값에 가까워지는데, 이것을 **대수의 법칙**이라 합니다.

- **주관적:** '이번 신규 장비는 처음이라 데이터가 없지만, 경험상 2% 정도일 것 같아' (믿음).

✔ 꼭 기억하기

'실험을 무한히 반복했을 때 상대 빈도의 극한' = **빈도적(통계적) 해석**.

'경우의 수 비율' = 고전적, '개인의 믿음' = 주관적(베이지안).

3 장. 통계 기초 — 데이터의 중심과 '퍼짐'

데이터를 요약하는 숫자는 두 종류입니다. 하나는 **중심**(평균·중앙값·최빈값), 다른 하나는 **퍼짐**(변동성)입니다. 시험에서 특히 중요한 것은 '퍼짐'을 재는 여러 방법, 즉 **분산의 종류**입니다.

3-1. 중심을 나타내는 값 (간단 정리)

- **평균(Mean):** 모든 값을 더해 개수로 나눈 값. 가장 흔하지만 극단값에 약함.
- **중앙값(Median):** 크기순으로 줄 세웠을 때 한가운데 값. 극단값에 강함.
- **최빈값(Mode):** 가장 자주 나오는 값.

3-2. '퍼짐(변동성)'을 재는 값 — 분산의 종류 ★

평균이 같아도 데이터가 '얼마나 들쭉날쭉한가'는 완전히 다를 수 있습니다. 이 들쭉날쭉함(산포도)을 재는 대표적인 척도들입니다.

척도	뜻	특징 / 언제 쓰나
범위(Range)	최댓값 - 최솟값	계산은 쉽지만 양 끝값만 봐서 극단값에 매우 약함
분산(Variance)	각 값이 평균에서 떨어진 거리를 제곱 해 평균낸 값	모든 데이터를 반영. 단, 단위가 '제곱'이라 직관적이지 않음
표준편차(Std)	분산의 제곱근	단위가 원래 데이터와 같아 해석이 쉬움 (가장 많이 씀)
사분위수 범위(IQR)	Q3(상위 25%) - Q1(하위 25%)	가운데 50%만 봐서 극단값(이상치)에 강함
변동계수(CV)	표준편차 ÷ 평균 (%)	단위가 다른 두 데이터의 퍼짐을 '상대적으로' 비교할 때

● 모분산 vs 표본분산 — 가장 헷갈리는 한 쌍

분산은 '대상이 누구냐'에 따라 두 가지로 나뉩니다. 시험에 자주 나오는 구분입니다.

구분	대상	나누는 수(분모)	기호
모분산	모집단 전체(전수)	N	σ^2
표본분산	표본(일부만 뽑음)	$n - 1$ (자유도 보정)	s^2

표본분산에서 n 이 아니라 **$n-1$** 로 나누는 이유는, 일부만 보고 전체를 추정할 때 분산을 너무 작게 잡는 경향을 바로잡기 위해서입니다(이를 **자유도 보정**, 그 결과를 **불편추정량**이라 합니다).

□ 쉽게 이해하기 — 두 메모리 라인의 품질

A 라인과 B 라인이 만든 칩의 **평균 속도가 똑같이 3200MHz** 라고 합시다. 그럼 두 라인은 같은 품질일까요? 아닙니다.

- A 라인: 3195~3205MHz 에 몰려 있음 → 표준편차 작음 → **균일한 고품질**.
- B 라인: 3000~3400MHz 로 들쭉날쭉 → 표준편차 큼 → **품질 편차 심함**.

즉 '평균'만 봐서는 품질을 알 수 없고, **분산·표준편차(퍼짐)** 를 함께 봐야 합니다. 이것이 분산을 배우는 이유입니다.

또, 전 세계에 출하된 칩 전부를 조사하면 **모분산**, 창고에서 100 개만 샘플링해 추정하면 **표본분산** 입니다.

3-3. 두 변수의 관계 — 공분산과 상관계수 ★

지금까지는 한 변수의 퍼짐이었고, 이제 **두 변수가 함께 어떻게 움직이는가**를 봅니다.

개념	무엇을 알려주나	값의 범위	주의점
공분산(Covariance)	두 변수가 같은 방향(+)/반대 방향(-)으로 움직이는지	제한 없음(단위에 따라 값이 천차만별)	크기로 '강도'를 비교하기 어려움
상관계수(Correlation)	두 변수의 선형 관계의 방향과 강도	-1 ~ +1	단위와 무관해 비교가 쉬움

- **부호:** +면 함께 증가, -면 한쪽이 오를 때 다른 쪽은 내려감.
- **크기(절댓값):** 1에 가까울수록 강한 직선 관계, 0에 가까울수록 직선 관계가 약함.

□ 쉽게 이해하기 — 전압과 전류

‘전압을 올리면 전류도 오른다’처럼 두 값이 함께 움직이는 정도를 잴 것이 공분산·상관계수입니다.

공분산은 단위(V·A)에 따라 값이 커졌다 작아졌다 해서 ‘얼마나 강한지’ 비교가 어렵습니다. 그래서 이를 $-1 \sim +1$ 로 **정규화**한 것이 **상관계수**입니다. 상관계수 $+0.95$ 면 ‘아주 강하게 비례’, -0.9 면 ‘아주 강하게 반비례’.

□ 단, 상관계수 0이 ‘아무 관계 없음’을 뜻하지는 않습니다. 곡선(U자) 관계는 직선 척도인 상관계수로 못 잡습니다.

✔꼭 기억하기

상관계수는 항상 -1 과 $+1$ 사이, 두 변수의 **선형 관계 강도**를 나타낸다.

공분산이 0이라고 두 변수가 ‘완전 무관’인 것은 아니다(비선형 관계 가능).

4 장. 확률 변수 — 이산형과 연속형

4-1. 확률 변수란?

확률 변수(Random Variable)는 ‘실험의 각 결과를 하나의 숫자에 대응시키는 함수’입니다. 예를 들어 동전 2개를 던질 때 ‘앞면의 개수’를 0, 1, 2라는 숫자로 바꿔 주는 규칙이 확률 변수입니다.

□ 쉽게 이해하기 — 검사 결과에 번호 붙이기

칩 하나를 검사하면 결과는 ‘양품/불량’이라는 말입니다. 컴퓨터로 다루려면 숫자가 필요하죠. 그래서 양품=0, 불량=1처럼 **결과(사건)를 숫자로 바꿔 주는 규칙**이 바로 확률 변수입니다.

즉 확률 변수는 ‘확률값 그 자체’가 아니라, **결과를 실수에 대응시키는 함수**라는 점이 핵심입니다.

4-2. 이산형 vs 연속형 ★

구분	값의 형태	확률 함수	특정 한 점의 확률	예시
이산형	셀 수 있는 값(0,1,2...)	확률 질량 함수 PMF	0 보다 클 수 있음	불량 개수, 주사위 눈
연속형	구간 안의 모든 실수	확률 밀도 함수 PDF	항상 0 ($P(X=x)=0$)	키, 몸무게, 온도, 수명

□ 쉽게 이해하기 — '정확히 3.000...초'는 확률 0

칩의 응답 시간이 '정확히 3 초'일 확률은 얼마일까요? 연속형에서는 3.0000...처럼 무한히 정밀한 한 점을 딱 맞출 확률은 **0** 입니다. 대신 '2.9 초~3.1 초 사이일 확률'처럼 **구간**으로 물어야 의미가 있습니다.

반대로 '불량 칩 개수가 정확히 3 개'는 셀 수 있으므로 그 확률이 0 이 아닙니다(이산형).

정리: 연속형은 **구간**으로, 이산형은 **개별 값**으로 확률을 따진다.

5 장. 이산형 확률 분포 — 어떤 상황에 어떤 분포?

'셀 수 있는' 결과들이 어떻게 분포하는지를 다룹니다. 각 분포가 '어떤 질문에 답하는가'로 외우면 쉽습니다.

분포	답하는 질문	한 줄 예시
베르누이	한 번 시도 → 성공/실패?	칩 하나가 양품인가 불량인가
이항(Binomial)	n 번 시도 중 성공이 몇 번?	100 개 중 불량 개수
포아송(Poisson)	일정 시간/공간에 사건이 몇 번?	웨이퍼 1 장당 결함 점 수
기하(Geometric)	첫 성공까지 몇 번 걸리나?	첫 불량이 나올 때까지 검사 횟수
초기하	비복원 추출에서 성공 개수?	한 상자에서 비복원으로 꺼낸 불량 수

□ 쉽게 이해하기 & 함정 주의

'셀 수 있으면 이산형'입니다. 포아송·기하·베르누이·이항·초기하는 모두 이산형입니다.

□ **균일 분포(연속균일, Uniform)** 는 '구간 안 아무 실수나 똑같은 가능성'이므로 **연속형** 입니다. 이름이 비슷해 이산형으로 착각하기 쉬우니 주의하세요.

6 장. 연속형 확률 분포 — 정규·지수·카이제곱·t·F

분포	핵심 특징 / 용도	한 줄 비유
정규(Normal)	종 모양. 자연·공정 데이터의 기본 분포	칩 속도 분포의 '기본 모양'
지수(Exponential)	무기억성 . 어떤 사건까지 걸리는 '대기 시간'	다음 고장까지 걸리는 시간
카이제곱(Chi-Square)	분산 검정·범주형 적합도/독립성 검정에 사용	불량 유형 분포가 기대와 맞나
t 분포	표본이 작고 모분산을 모를 때 평균 검정	샘플 20 개로 평균 비교
F 분포	두 분산의 비. ANOVA 의 기반	여러 라인의 분산 비교

□ 쉽게 이해하기 — 지수 분포의 '무기억성'

메모리 모듈이 '평균 5 년에 한 번 고장'난다고 합시다. 이미 3 년을 멀쩡히 썼다면, 앞으로 고장까지 남은 시간이 줄어 들었을까요? 지수 분포에서는 '**이미 얼마를 썼든, 앞으로 걸릴 시간의 분포는 똑같다**' 고 봅니다. 마치 과거를 '기억하지 못하는' 것과 같아서 **무기억성(Memoryless)** 이라 부릅니다.

'사건이 일어날 때까지의 대기 시간' → 지수 분포, 라고 연결해 두면 됩니다.

7 장. 가설 검정 — '정말 차이가 있나?'를 판정하기

7-1. 기본 용어부터

- **귀무가설(H0):** '차이가 없다 / 효과가 없다'는 기본 입장(보수적인 쪽).
- **대립가설(H1):** '차이가 있다 / 효과가 있다' — 우리가 입증하고 싶은 주장.

- **유의수준(α)**: 보통 0.05. '이 정도 드문 일이면 우연이 아니라고 보겠다'는 기준선.
- **p-value**: 데이터가 보여준 결과(또는 더 극단적인 결과)가 '귀무가설이 참일 때' 나올 확률.
- **판정 규칙**: $p < 0.05 \rightarrow$ 귀무가설 기각(차이 있다), $p \geq 0.05 \rightarrow$ 기각 못함(차이 있다고 말 못함).

□ 쉽게 이해하기 — 신약 검정과 p-value

'신약이 위약보다 혈압을 더 낮춘다'를 증명하고 싶다고 합시다.

- 귀무가설 H_0 = '신약과 위약은 차이가 없다' (재판의 '무죄 추정'과 같음).
- p-value 0.01 은 '만약 둘이 정말 차이가 없다면, 이런 결과가 우연히 나올 확률은 1%뿐'이라는 뜻.
- 1%는 0.05 보다 작으니 '우연이라기엔 너무 드물다' $\rightarrow$ 귀무가설 기각 $\rightarrow$ '신약 효과가 있다' 결론.

□ 자주 하는 실수: H_0 는 항상 '효과 없다/차이 없다' 쪽입니다. '신약은 효과가 있다'는 H_0 가 아니라 H_1 입니다.

7-2. 두 가지 오류와 유의수준 ★

	실제로 H_0 가 참(차이 없음)	실제로 H_0 가 거짓(차이 있음)
H_0 기각함	제 1 종 오류(α) — 없는 차이를 있다고 함	올바른 판정
H_0 기각 못함	올바른 판정	제 2 종 오류(β) — 있는 차이를 놓침

✔꼭 기억하기 — 두 오류는 동시에 0 이 될 수 없다

제 1 종 오류를 줄이려고 기준(α)을 뽁뽁하게 하면, 진짜 차이를 놓치는 제 2 종 오류가 늘어납니다. 둘은 시소 관계라 **동시에 0 으로 만들 수 없습니다**. 유의 수준은 이 둘 사이의 '타협점'을 정하는 것일 뿐입니다.

□ 비유: 불량 검출 기준을 너무 엄격히 하면 양품까지 불량으로 버리고(1 종), 너무 느슨히 하면 불량이 출하됨(2 종).

7-3. 가설 검정의 종류 ★★

'무엇을, 어떤 데이터로 비교하느냐'에 따라 알맞은 검정이 다릅니다.

검정	언제 쓰나	예시
단일표본 t-검정	한 집단 평균이 기준값과 다른가	이 라인 칩 두께 평균이 규격 50nm 인가
독립표본 t-검정	서로 다른 두 집단의 평균 비교	A 라인 vs B 라인 평균 두께
대응표본 t-검정	같은 대상의 전·후 비교	공정 개선 전후 같은 설비의 수율
Z-검정	표본이 크고($n \geq 30$) 모분산을 알 때 평균 검정	대량 생산 데이터의 평균 검정
F-검정	두 집단의 분산이 같은지, ANOVA의 기반	두 라인의 산포가 같은가
카이제곱 검정	범주형 데이터의 적합도·독립성	불량 유형과 라인이 관련 있나

□ 쉽게 이해하기 — t-검정 3 형제 구분

- **단일표본**: 우리 라인 하나를 '규격 기준값'과 비교 (상대가 숫자 하나).
- **독립표본**: 서로 남남인 두 라인(A, B)을 비교.
- **대응표본**: '같은' 설비를 개선 전/후로 두 번 측정해 비교 (짝지어진 데이터).

참고: 모분산을 알면 Z-검정, 모르면 t-검정. 보통 현실에선 모분산을 모르므로 t-검정을 씁니다.

8 장. 회귀 분석 — 관계를 '식'으로 예측하기

8-1. 단순 선형 회귀의 기본 가정 ★

회귀 결과를 믿으려면 다음 가정들이 만족되어야 합니다.

- **선형성**: 독립변수와 종속변수가 직선 관계.
- **독립성**: 관측값(잔차)들이 서로 독립. ← 서로 강하게 상관되면 안 됨!

- **등분산성**: 잔차의 퍼짐이 어디서나 일정.
- **정규성**: 잔차가 정규분포를 따름.

✔ 꼭 기억하기

'잔차들이 서로 강한 상관관계'를 가질수록 모형이 정확해진다'는 틀린 말입니다. 오히려 잔차는 서로 독립이어야 하고, 잔차에 패턴이 남아 있다는 것은 모형이 무언가를 놓쳤다는 신호입니다.

8-2. 어떤 회귀를 쓸까

기법	언제 쓰나	예시
단순/다중 선형 회귀	연속형 숫자를 예측	전압으로 칩 속도(MHz) 예측
로지스틱 회귀	범주형(예/아니오) 결과를 예측	대출 승인/거절, 양품/불량 분류
다항 회귀	곡선 관계를 직선식 확장으로 표현	비선형 공정 곡선
릿지 회귀	변수 많을 때 과적합 억제	다중공선성 있는 데이터

□ 쉽게 이해하기 — '얼마?' vs '예/아니오?'

- 결과가 '속도 몇 MHz?'처럼 연속된 숫자면 → 선형 회귀.
 - 결과가 '승인이냐 거절이냐', '양품이냐 불량이냐'처럼 둘 중 하나(범주)면 → 로지스틱 회귀.
- 이름은 '회귀'지만 로지스틱 회귀는 사실상 분류에 쓰입니다.

8-3. 회귀 결과표 읽는 법 (coef, p-value)

회귀 결과표에서 각 변수의 **p-value** 를 보고 '그 변수가 결과에 유의미한 영향을 주는가'를 판단합니다. $p < 0.05$ 면 유의미, $p \geq 0.05$ 면 유의하지 않음 입니다. coef(계수)의 부호는 영향의 방향을 뜻합니다.

□ 쉽게 이해하기 — 어떤 공정 변수가 중요한가

4 개 공정 변수 A·B·C·D 의 회귀 결과에서 A·B·C 는 p-value 가 0.05 보다 작고 D 만 0.53 이라면, 'A·B·C 는 결과에 유의미한 영향, D 는 영향이 통계적으로 유의하지 않다'고 읽습니다.
계수가 양수라고 무조건 '중요/높여라'가 아니라, 먼저 **p-value** 로 **유의성**부터 확인해야 합니다.

9 장. 분산 분석(ANOVA) — 세 집단 이상을 한 번에 비교

9-1. 왜 ANOVA 가 필요한가 ★

t-검정은 두 집단까지만 비교합니다. 세 집단(A·B·C)을 t-검정으로 A-B, B-C, A-C 따로따로 반복 비교하면 **제 1 종 오류가 누적**되어 '실제로는 차이가 없는데 있다'고 잘못 판정할 위험이 커집니다. ANOVA 는 이 누적 문제를 피하면서 **세 집단 이상을 한 번에** 비교합니다.

□ 쉽게 이해하기 — 집단 '사이' vs 집단 '안'의 분산

ANOVA 의 핵심 아이디어: 전체 변동을 '집단 간 변동'(라인 A·B·C 평균끼리 차이) 과 '집단 내 변동'(같은 라인 안의 자연스러운 들쭉날쭉) 으로 쪼갭니다.

'집단 간 변동'이 '집단 내 변동'보다 충분히 크면(F 비가 크면) → '라인끼리 진짜 차이가 있다'고 판정합니다.

단, ANOVA 는 '적어도 한 집단이 다르다'까지만 알려줄 뿐, **어느 라인이 다른지**는 사후검정(Tukey 등)으로 따로 확인합니다.

9-2. 분산 분석의 종류 ★★

종류	요인(독립변수) 수 / 상황	예시
일원배치(One-Way)	요인 1 개 , 집단 3 개 이상	식각 가스 A·B·C 에 따른 수율
이원배치(Two-Way)	요인 2 개 + 상호작용	가스 종류 × 온도가 수율에 미치는 영향
반복측정(Repeated)	같은 대상 을 여러 번 측정	같은 웨이퍼를 시점별로 반복 측정
다변량(MANOVA)	종속변수 여러 개 동시 분석	수율·두께·저항을 한 번에

✔ 꼭 기억하기

일원배치 ANOVA = 요인 1 개로 나뉜 **세 집단 이상의 평균을**, 1 종 오류 누적 없이 한 번에 비교.

ANOVA 적용 조건: 독립성, 정규성, **등분산성**(모든 집단의 분산이 같아야 함 — '서로 달라야'가 아님).

10 장. 상관 분석 — 두 변수의 관계 측정

10-1. 상관 분석의 종류 ★★

데이터의 '종류'에 따라 알맞은 상관계수가 다릅니다.

상관계수	언제 쓰나(데이터 종류)	예시
피어슨	두 변수 모두 연속형 + 직선 관계	전압과 전류, 엔진 크기와 연비
스피어만(순위)	순위형 또는 곡선·이상치가 있는 경우	만족도 순위와 재구매 순위
켄달의 타우	표본이 작고 순위 자료일 때	소수 샘플의 순위 일치도
점-이계열	한쪽이 이진(양품/불량) , 다른 쪽 연속형	합격 여부와 시험 점수

10-2. 상관계수 해석과 가장 중요한 함정 ★

상관계수는 $-1 \sim +1$. 절댓값이 1 에 가까울수록 강한 직선 관계입니다. 예를 들어 **-0.9** 면 '한 변수가 커질수록 다른 변수는 대체로 작아지는, 매우 강한 반비례 경향'입니다.

□ 쉽게 이해하기 — 엔진 크기와 연비

'엔진 크기와 연비의 피어슨 상관계수 = -0.9'를 읽어 봅시다.

- 부호 -: 엔진이 커질수록 연비는 **대체로 낮아지는 경향**.
- 크기 0.9: 그 경향이 **매우 강함**.

□ 단, '엔진이 연비를 낮추는 직접적인 원인'이라고 단정하면 안 됩니다(상관 ≠ 인과).

✔ 꼭 기억하기 — 상관관계 ≠ 인과관계

두 변수가 강하게 함께 움직여도 한쪽이 다른 쪽의 '원인'이라는 보장은 없습니다. 숨은 **제 3의 변수(교란변수)**가 둘 다를 움직이는 경우가 많습니다.

□ 비유: '안전 교육 횟수'와 '재해 건수'가 함께 늘었다면, 교육이 재해를 유발한 게 아니라 '신규 직원 수 증가' 같은 제 3의 변수가 둘 다를 끌어올렸을 수 있습니다. (여름철 아이스크림 판매량과 익사 사고가 함께 늘는 것도 '더운 날씨' 때문이듯이.)

11 장. 완전 요인 실험 — 모든 조합을 실험하기

11-1. 꼭 알아야 할 용어

용어	뜻	예시
요인(Factor)	실험에서 의도적으로 바꾸는 변수	온도, 압력, 가스 농도
수준(Level)	각 요인이 갖는 값/상태	저수준(-1)=30°C, 고수준(+1)=50°C
처리 조합/런(Run)	각 요인의 수준을 하나씩 골라 만든 한 번의 실험 조건	(고온, 저압) 한 세트
주효과(Main Effect)	한 요인 단독이 결과에 미치는 평균 영향	온도만의 효과
상호작용 효과	한 요인의 효과가 다른 요인 수준에 따라 달라지는 현상	온도 효과가 압력에 따라 변함

□ 쉽게 이해하기 — OFAT의 함정과 완전 요인의 장점

OFAT(한 번에 한 요인만 바꾸기)는 '온도만 바꾸고, 다음엔 압력만 바꾸고...' 식입니다. 단순하지만 '온도가 높을 때만 압력을 올려야 수율이 오르는' 같은 **상호작용**을 절대 못 잡습니다.

완전 요인 실험은 모든 조합을 다 해 보므로, **주효과뿐 아니라 상호작용 효과까지** 정확히 추정합니다. 이것이 OFAT 대비 가장 큰 장점입니다.

□ 함정: '상호작용 효과 = 한 요인이 단독으로 미치는 영향'은 틀린 정의입니다. 그건 주효과입니다.

단점: 요인이 늘면 실험 횟수가 2의 거듭제곱(2^k)으로 **기하급수적으로** 증가합니다(요인 5 개면 32 회). 그래서 요인이 많으면 다음 장의 부분 요인 실험을 씁니다.

12 장. 부분 요인 실험 — 똑똑하게 일부만 실험하기

부분 요인 실험($2^{(k-p)}$)은 완전 요인의 일부 조합만 골라 실험하는 방법입니다. '실험 횟수 폭발' 문제를 완화하면서 핵심 요인을 빠르게 추려냅니다.

- **스크리닝**: 후보 요인 중 영향이 큰 핵심 요인을 빠르게 선별하는 단계에 유용.
- **회소성 원리(Effect Sparsity)**: '고차 상호작용은 대체로 무시할 만큼 작다'는 경험칙을 활용.
- **교락(Confounding)**: 실험을 줄인 대가로 일부 효과들이 서로 뒤섞여 구분이 어려워지는 '정보 손실'이 생김.

✔ 꼭 기억하기

부분 요인 실험은 '**일부만**' 실험하므로, 완전 요인보다 **항상 더 정밀한** 것이 아닙니다. 오히려 교락에 따른 정보 손실을 감수하는 대신 **횟수를 줄이고 핵심 요인을 빨리 찾는** 데 목적이 있습니다.

□ 쉽게 이해하기 — 4개 변수 중 중요한 것 찾기

공정 변수 A·B·C·D 중 무엇이 중요한지 빨리 알고 싶을 때 $2^{(4-1)}$ 부분 요인 실험을 합니다. 결과표에서 A·B·C는 $p < 0.05$ (유의), D는 $p = 0.53$ (유의하지 않음)이면 → '**D는 빼도 되는 변수**, A·B·C에 집중하자'고 결론 내립니다. 이것이 스크리닝의 힘입니다.

14 장. 다구찌 방법 — ‘흔들리지 않는’ 강건한 설계

다구찌 방법의 철학은 ‘평균 성능을 높이는 것’을 넘어, **잡음이 있어도 성능이 흔들리지 않는 강건한(robust) 제품·공정**을 설계하는 것입니다.

용어	뜻
제어 인자(Control Factor)	설계자가 원하는 수준으로 조절 가능한 인자 (온도, 압력, 재료비율)
잡음 인자(Noise Factor)	제어하기 어렵거나 비용이 큰 인자 (사용 환경, 원자재 편차, 측정 오차)
S/N 비	신호(원하는 성능) 대비 잡음(변동)의 비율. 클수록 좋은 설계
직교배열표(OA)	적은 횟수로 효율적으로 실험하도록 짠 표 (예: L9)

□ 쉽게 이해하기 — 어디서 써도 잘 도는 메모리

메모리 모듈을 만들 때, 어떤 사용자는 시원한 사무실에서, 어떤 사용자는 더운 차 안에서 씁니다(=잡음 인자: 온도). 다구찌의 목표는 ‘실험실에서만 빠른’ 제품이 아니라, **온도가 변해도 성능이 거의 안 흔들리는** 설계 조건을 찾는 것입니다.

- 우리가 조절할 수 있는 전압·클럭 = **제어 인자**.
- 우리가 어쩔 수 없는 사용 환경 온도 = **잡음 인자**.
- 잡음 대비 신호가 큰 정도 = **S/N 비** (클수록 안정적). 다구찌는 S/N 비를 ‘최대화’합니다.

□ 함정: 다구찌의 목표는 잡음 인자를 ‘완전히 제거’하는 것이 아니라(불가능), 잡음이 있어도 **둔감하게** 만드는 것입니다.

15 장. 블록 설계 — ‘알려진 차이’를 묶어서 제거하기

블록 설계(Block Design) 는 실험 단위들 사이에 존재하는 **알려진 이질성(변동)** 을 ‘블록’으로 묶어 통제함으로써, 우리가 보고 싶은 **처리 효과**를 더 **정밀하게** 추정하는 방법입니다.

□ 쉽게 이해하기 — 설비마다 다른 메모리 라인

3 가지 공정 조건(처리)을 비교하고 싶은데, 공장에 성능이 제각각인 설비 5 대가 있습니다. 설비 차이를 무시하면 ‘조건 차이’인지 ‘설비 차이’인지 뒤섞여 버립니다.

그래서 **설비 하나하나를 ‘블록’으로 묶고**, 각 설비 안에서 3 가지 조건을 모두 시험합니다. 그러면 ‘설비 간 차이’를 통계적으로 걷어내고 순수한 **조건(처리) 효과**만 또렷하게 볼 수 있습니다.

대표적 방법: **난괴법(RCBD)** — 각 블록이 모든 처리를 한 번씩 포함.

✔ 꼭 기억하기

블록 설계의 목적은 요인을 늘리거나 비용을 줄이는 게 아니라, **알려진 이질성(변동)**을 통제해 **처리 효과**를 더 **정밀하게** 추정하는 것.