

확률통계 · 실험계획법

요약정리

0. 큰 그림 — 통계를 ‘공장’으로 이해하기

통계와 실험계획법은 결국 ‘들쭉날쭉한 현실 속에서 진짜 신호를 찾아내는 기술’입니다. 공정에는 늘 잡음(노이즈)이 섞여 있고, 우리는 한정된 표본으로 전체(모집단)를 추정하고, 차이가 ‘우연인지 진짜인지’를 판정하며, 실험을 똑똑하게 설계해 원인을 가려냅니다. 아래 흐름이 이 과정 전체의 지도입니다.

- 확률 → 확률변수·분포 → (표본으로) 추정·검정 → 관계 분석(회귀·상관·ANOVA) → 실험설계(DOE)로 원인 찾기

1 부. 확률의 기초

1-1. 확률을 해석하는 세 가지 관점

같은 ‘확률’이라는 말도 누가·어떤 상황에서 쓰느냐에 따라 의미가 조금씩 다릅니다.

관점	정의	예시
고전적(수학적)	모든 경우가 동등하다고 보고 (원하는 경우의 수)/(전체 경우의 수)로 계산	주사위 6 면, 동전 앞뒤
빈도적(통계적)	같은 실험을 무한히 반복했을 때 나타나는 상대빈도의 극한	수많은 제품 중 불량률
주관적(베이지안)	믿음의 정도를 확률로 표현, 새 정보로 갱신	‘이 신제품이 성공할 확률 70%’

1-2. 조건부확률과 독립

- 조건부확률 $P(A|B)$: 사건 B 가 일어났다는 조건에서 A 가 일어날 확률.
- 독립 : 한 사건이 다른 사건에 영향을 주지 않음. 독립이면 $P(A \cap B) = P(A) \times P(B)$ 가 성립한다. ★
- 배반(서로소)과 독립은 다르다 : 배반은 '동시에 못 일어남', 독립은 '서로 영향 없음'. 배반이라고 독립인 것이 아니다.

※ $P(A|B)$ 와 $P(B|A)$ 는 일반적으로 다르다. (조건이 무엇이냐가 다르기 때문)

2 부. 확률 변수 — 기댓값과 분산

2-1. 확률 변수란?

확률 변수(Random Variable)는 '실험의 각 결과를 하나의 숫자에 대응시키는 함수'입니다.

예: 동전 2 개를 던질 때 '앞면의 개수'를 0, 1, 2 로 바꿔 주는 규칙.

2-2. 기댓값 $E(X)$ — '장기적인 평균'

기댓값은 확률변수가 가질 수 있는 각 값에 그 확률을 곱해 모두 더한 값으로, 실험을 아주 여러 번 반복했을 때의 평균을 뜻합니다. $E(X) = \sum x \cdot P(X = x)$

예) 주사위 한 번의 기댓값 = $1 \cdot (1/6) + 2 \cdot (1/6) + \dots + 6 \cdot (1/6) = 3.5$. '한 번 던져 3.5 가 나온다'가 아니라 '여러 번 던지면 평균이 3.5 에 수렴'이라는 뜻입니다.

2-3. 분산·표준편차와 선형변환

- 분산 $\text{Var}(X)$: 값들이 평균에서 얼마나 퍼져 있는지. 표준편차 = $\sqrt{\text{분산}}$.
- 선형변환 : $Y = aX + b$ 이면 $\text{Var}(Y) = a^2 \cdot \text{Var}(X)$, 표준편차는 $|a|$ 배. 상수 b (평행이동)는 퍼짐을 바꾸지 않는다.

※ 예) $Y = 2X + 5 \rightarrow \text{Var}(Y) = 4 \cdot \text{Var}(X)$. 더한 5 는 분산에 영향이 없다.

2-4. 이산형 vs 연속형 — PMF 와 PDF

구분	이산형	연속형
값	셀 수 있음(0,1,2,...)	구간 안의 모든 실수
확률 표현	확률질량함수(PMF)	확률밀도함수(PDF)
한 점의 확률	$P(X=x) > 0$ 가능	$P(X=x) = 0$ (항상)
구간 확률	해당 값들의 합	곡선 아래 넓이(적분)
예	주사위 눈, 불량 개수	키·몸무게·온도·시간

※ 연속형에서 밀도값 $f(x)$ 자체는 '확률'이 아니다(1 보다 클 수도 있음). 확률은 언제나 '구간의 넓이'로 구한다.

3 부. 주요 확률 분포 — 어떤 상황에 어떤 분포?

3-1. 이산형 분포

분포	답하는 질문	핵심 숫자
베르누이	한 번 시행에서 성공/실패?	성공확률 p
이항(Binomial)	성공확률 p 인 시행을 n 번 했을 때 성공 횟수는?	평균 = $n \cdot p$, 분산 = $n \cdot p \cdot (1-p)$
포아송(Poisson)	단위 시간·공간당 드물게 일어나는 사건의 횟수는?	평균 = 분산 = λ
기하(Geometric)	처음 성공이 나올 때까지 시행 횟수는?	성공확률 p

3-2. 연속형 분포

분포	쓰임	특징
정규(Normal)	자연·공정의 가장 흔한 분포	좌우대칭 종 모양, 평균·표준편차로 결정
지수(Exponential)	다음 사건까지 걸리는 시간(대기시간)	무기역성, 평균 = $1/\lambda$
연속균일(Uniform)	구간 안에서 고르게	구간 양 끝만 다름
카이제곱·t·F	가설검정·분산분석에 사용	검정 통계량의 분포

3-3. 정규분포와 표준화(Z-점수)

- 68-95-99.7 규칙 : 데이터의 약 68%가 평균 $\pm 1\sigma$, 약 95%가 $\pm 2\sigma$, 약 99.7%가 $\pm 3\sigma$ 안에 들어온다.
- 표준정규분포 : 평균 0, 표준편차 1 인 정규분포 $N(0,1)$.
- 표준화(Z-점수) : $Z = (x - \mu) / \sigma$. '평균에서 표준편차 몇 칸 떨어졌나'를 뜻한다. ★

※ 예) 평균 70, 표준편차 10 인 시험에서 90 점 $\rightarrow Z = (90-70)/10 = 2.0$ (평균보다 2σ 위, 상위권).

3-4. 표본평균과 중심극한정리(CLT)

- 표준오차 : 표본평균이 흔들리는 정도 = $\sigma/\sqrt{n}$. 표본 크기 n 이 커질수록 작아진다(추정이 안정).
- 중심극한정리 : 표본 크기가 충분히 크면, 모집단이 어떤 분포든 표본평균의 분포는 정규분포에 가까워진다. ★

4 부. 추정과 가설 검정

4-1. 점추정·구간추정·신뢰구간

- 점추정 : 모수를 하나의 값으로 추정(예: 평균은 14.0).
- 구간추정(신뢰구간) : 모수가 있을 법한 범위로 추정(예: 95% 신뢰구간 [12.4, 15.6]).

95% 신뢰구간의 올바른 해석 ★ : '같은 방법으로 표본추출과 구간추정을 여러 번 반복하면, 그렇게 만든 구간들의 약 95%가 모평균을 포함한다'는 뜻입니다. '이 특정 구간 안에 모평균이 있을 확률이 95%'라는 표현은 흔한 오해입니다. 또한 신뢰수준을 99%로 높이면 더 확실히 잡으려는 만큼 구간 폭은 넓어집니다.

4-2. 가설 검정의 기본 용어

- 귀무가설 H_0 : '차이가 없다/효과가 없다'는 보수적 기준.
- 대립가설 H_1 : '차이가 있다/효과가 있다' — 우리가 입증하려는 주장.
- 유의수준 α : 보통 0.05. '이 정도로 드문 일이면 우연이 아니라고 보겠다'는 기준선.
- 판정 : $p < 0.05 \rightarrow$ 귀무가설 기각(차이 있다), $p \geq 0.05 \rightarrow$ 기각 못함(차이 있다고 말 못함).

4-3. 두 가지 오류

	H0 가 실제로 참	H0 가 실제로 거짓
H0 기각	제 1 종 오류(α) — 없는 차이를 있다고 함	옳은 판정 (검정력 $1-\beta$)
H0 기각 못함	옳은 판정	제 2 종 오류(β) — 있는 차이를 놓침

제 1 종 오류는 '귀무가설이 참인데도 기각하는' 오류이고, 그 확률의 최대 허용치가 유의수준 α 입니다. 제 1 종과 제 2 종은 한쪽을 줄이면 다른 쪽이 커지는 상충 관계라, 둘을 동시에 0 으로 만들 수는 없습니다. ★

4-4. p-value 바로 알기

- 정의 : 귀무가설이 참이라고 가정했을 때, 관측된 결과(또는 더 극단적 결과)가 나올 확률.
- 작을수록 '우연으로 보기 어렵다' $\rightarrow$ 귀무가설을 기각하는 근거. $p < \alpha$ 면 기각.

※ p-value 는 '귀무가설이 참일 확률'이 아니다. 또한 0.05 로 고정된 값도 아니다(데이터마다 계산됨).

4-5. 가설 검정의 종류

검정	언제 쓰나
t-검정(단일/독립/대응)	평균 비교(모표준편차 모를 때, 두 집단까지)
Z-검정	평균 비교(표본 크고 모표준편차를 알 때)
F-검정	분산 비교, 분산분석의 기반
카이제곱 검정	범주형 데이터의 적합도·독립성
비모수 검정	정규성 가정이 어려울 때(순위 기반)

※ 독립표본 t-검정 실행 결과 예 : 't-통계량: 1.2700 / p-값: 0.2100' → $p=0.21 \geq 0.05$ 이므로
 귀무가설을 기각하지 못함 = '두 집단 평균 차이가 통계적으로 유의하다고 보기 어렵다'.
 (반대로 p-값이 0.01 이면 유의)

5 부. 회귀 분석 — 관계를 '식'으로 예측

5-1. 단순 선형 회귀의 기본 가정

- 선형성 : 독립변수와 종속변수가 직선 관계.
- 독립성 : 관측값(잔차)들이 서로 독립. ← 잔차가 서로 강하게 상관되면 오히려 가정 위배(정확해지는 것이 아님).
- 등분산성 : 잔차의 퍼짐이 어디서나 일정.
- 정규성 : 잔차가 정규분포를 따름.

5-2. 회귀식 해석 — 기울기와 절편

추정식이 $\hat{y} = a + b \cdot x$ 일 때, 기울기 b 는 'x 가 1 단위 증가할 때 y 가 평균적으로 b 만큼 변한다'는 뜻이고, 절편 a 는 'x 가 0 일 때의 예측값'입니다.

※ 예) $\hat{y} = 2.5 + 0.8x \rightarrow x$ 가 1 늘면 y 는 평균 0.8 증가. (0.8 은 상관계수나 설명력이 아니라 '변화량')

5-3. 결정계수 R^2 해석

R^2 는 '종속변수의 전체 변동 중 회귀모형(독립변수)이 설명하는 비율'입니다. 0~1 사이이며 1에 가까울수록 설명력이 큼. $R^2=0.81$ 이면 'y의 변동 중 약 81%를 모형이 설명한다'는 뜻이지, '81% 확률로 정확'하거나 '인과적으로 81% 결정'한다는 뜻이 아닙니다.

5-4. 회귀 결과표 읽는 법 (coef, p-value)

각 변수의 p-value로 '그 변수가 결과에 유의미한 영향을 주는가'를 판단합니다. $p < 0.05$ 면 유의, $p \geq 0.05$ 면 유의하지 않음. coef(계수)의 부호는 영향의 방향입니다.

※ 예) A: coef 1.85, p 0.002 / B: 0.92, p 0.015 / C: 0.07, p 0.640 → A·B는 유의, C는 유의하지 않음. (p가 크다고 중요한 것이 아님)

5-5. 로지스틱 회귀 — 분류에 쓰는 회귀

'승인/거절', '합격/불량'처럼 범주(특히 둘 중 하나)를 예측할 때 사용합니다. 출력은 0과 1 사이의 확률값이며, 보통 0.5 같은 임계값을 기준으로 범주를 분류합니다. 연속 수치의 평균을 예측하는 일반 선형회귀와는 목적이 다릅니다.

6 부. 분산 분석(ANOVA) — 세 집단 이상 한 번에 비교

6-1. 왜 ANOVA가 필요한가

t-검정은 두 집단까지만 비교합니다. 세 집단(A·B·C)을 t-검정으로 따로따로 반복하면 제 1종 오류가 누적되어 위험합니다. ANOVA는 이 누적을 피하면서 한 번에 비교합니다.

6-2. ANOVA의 귀무가설

일원배치 분산분석의 귀무가설은 '비교하는 모든 집단의 평균이 서로 같다'입니다. 기각되면 '적어도 한 집단의 평균이 다르다'가 됩니다(어느 집단인지는 사후검정으로).

6-3. 분산 분석의 종류

종류	구분 기준
일원배치	요인 1 개
이원배치	요인 2 개(상호작용도 분석 가능)
반복측정	같은 대상을 여러 번 측정
MANOVA	종속변수가 2 개 이상

7 부. 상관 분석 — 두 변수의 관계 측정

7-1. 공분산과 상관계수

- 부호 : +면 함께 증가, -면 한쪽이 오를 때 다른 쪽은 내려감.
- 상관계수 r : $-1 \sim +1$. 절댓값이 1 에 가까울수록 강한 직선 관계, 0 에 가까울수록 직선 관계가 약함.

7-2. 해석과 가장 중요한 함정

- 값 해석 : $r=+0.88$ 이면 '한 변수가 커질수록 다른 변수도 대체로 함께 커지는 강한 경향'. $r=-0.9$ 면 강한 반비례 경향.
- $r \approx 0$ 의 의미 : '선형(직선) 관계가 약하다'는 뜻일 뿐, 곡선(비선형) 관계까지 없다는 보장은 아니다.
- 상관 $\neq$ 인과 : 강한 상관이 있어도 인과가 아닐 수 있다. '기온' 같은 제 3 의 변수(교란변수)가 두 값을 동시에 끌어올리는 경우가 대표적(예: 아이스크림 판매량과 물놀이 사고).

7-3. 상관 분석의 종류

종류	데이터 종류
피어슨	연속 $\times$ 연속(직선 관계)
스피어만	순위(서열) 데이터
켄달 타우	소표본 순위
점-이계열	이진 $\times$ 연속

8 부. 실험계획법(DOE) — 원인을 효율적으로 찾기

8-1. 실험계획의 3 대 기본 원칙

- 반복(Replication) : 같은 조건을 여러 번 실험 → 실험오차를 추정하고 결과의 신뢰성을 높임.
- 임의화(Randomization) : 실험 순서·배치를 무작위로 → 알지 못하는 외부 요인의 영향이 특정 처리에 치우치지 않게 함.
- 블록화(Blocking) : 알려진 이질성을 묶어 통제(8-6 참조).

8-2. OFAT vs 완전 요인 실험

한 번에 한 요인만 바꾸는 OFAT 와 달리, 완전 요인 실험은 모든 요인·수준 조합을 실험하여 각 요인의 주효과뿐 아니라 요인들이 결합해 나타나는 상호작용 효과까지 분석할 수 있습니다.

- 용어 : 요인(바꾸는 변수) · 수준(요인의 값, 예 $-1/+1$) · 처리조합(런, 한 실험 조건).
- 실험 횟수 : 2 수준 k 요인 완전요인 = 2^k 회. (예: 요인 3 개 → $2^3 = 8$ 회, 요인 5 개 → 32 회). 요인이 늘면 폭증한다.

8-3. 상호작용(Interaction) 효과란

두 요인 A·B 의 상호작용이 있다는 것은 'A 가 반응에 미치는 효과가 B 의 수준에 따라 달라진다'는 뜻입니다. 단순히 각 효과를 더한 것(합)과 다릅니다.

8-4. 부분 요인 실험 — 똑똑하게 일부만

- 목적 : 요인이 많을 때 실험 횟수 폭발을 완화. 핵심 요인을 빠르게 추리는 스크리닝에 유용.
- 희소성 원리(Effect Sparsity) : 고차 상호작용은 대체로 무시할 만큼 작다는 경험칙을 활용.

- 교락(Confounding/Aliasing) ★ : 실험을 줄인 대가로 서로 다른 효과(예: 어떤 주효과와 특정 상호작용)가 뒤섞여 분리 추정이 어려워지는 '정보 손실'이 생긴다. → 완전요인보다 항상 더 정밀한 것이 아님.

8-5. 다구찌 방법 — '흔들리지 않는' 강건 설계

다구찌 방법의 철학은 평균 성능을 높이는 것을 넘어, 잡음이 있어도 성능이 흔들리지 않는 강건한(robust) 제품·공정을 설계하는 것입니다.

- 제어 인자 : 설계자가 원하는 수준으로 조절할 수 있는 인자.
- 잡음 인자 : 온도·습도·사용환경처럼 통제하기 어려운(또는 비싼) 인자. 완전히 없애는 것이 목표가 아니라, 그 영향에 둔감하게 설계하는 것이 목표.
- S/N 비(신호 대 잡음 비) : 잡음 대비 신호의 비율. 값이 클수록 잡음에 강건한 좋은 설계.
- 직교 배열표(Orthogonal Array) : 비교적 적은 실험 횟수로 여러 요인의 효과를 균형 있게 평가하기 위한 표준 실험표.
- 품질 손실 함수 : 특성치가 목표값에서 벗어날수록 손실이 (대체로 제곱에 비례하여) 커진다고 본다. '규격 안에만 들면 손실 0'이라는 종래 관점과 다름.

8-6. 블록 설계 — 알려진 차이를 묶어 제거

블록 설계는 실험 단위 사이의 '알려진 이질성(변동)'을 블록으로 묶어 통제함으로써, 보고 싶은 처리 효과를 더 정밀하게 추정하는 방법입니다.

- 무엇을 블록으로? : 실험 날짜, 원자재 로트, 작업조, 장비처럼 '반응에 영향은 주지만 그 자체가 관심 대상은 아닌 변동 요인'을 블록으로 둔다. (관심 요인이나 반응 변수는 블록이 아니다)