


통계·실험계획 개념 지도

- [1] 확률·분포·검정·분석·DOE 가 어떻게 연결되는지 다이어그램으로 보는 전체 그림으로 이해
- [2] 데이터를 분석한 뒤 statsmodels 요약표에서 각 숫자가 무슨 뜻이고 값에 따라 어떻게 해석하는지 참고하는 기준표.

1. 전체 큰 그림 — 무엇이 무엇과 연결되는가

1.1 의존 관계

확률이 가장 밑바탕이고, 그 위에 분포, 검정, 분석이 차례로 쌓입니다. 위층(분석)은 아래층(검정·분포·확률)을 계산 도구로 "사용"합니다. 우리가 평소 "...한다"고 말하는 것은 맨 위의 분석(회귀·분산분석·상관)입니다.




[그림 1] 확률 → 분포 → 검정 → 분석의 의존 구조. DOE는 데이터 수집을 미리 설계하는 별도 단계.

[핵심 포인트]

분포는 두 얼굴을 가집니다. ① 데이터 자체가 어떻게 흩어지는가(정규·이항·포아송)와 ② 우리가 계산한 통계량이 어떻게 행동하는가(t -F· χ^2 -Z). 검정에서 쓰는 것은 주로 ②입니다.

1.2 작업 순서 — 실제로는 이렇게 흘러간다


의존 관계(무엇이 무엇을 떠받치나)와 작업 순서(시간상 무엇부터 하나)는 다릅니다. 시간 순서로는 DOE(설계)가 먼저고, 데이터를 모은 뒤 분석하고 해석합니다. 이미 데이터가 있으면 ②~③부터 시작합니다.



[그림 2] 시간 흐름: 설계 → 수집 → 분석 → 해석. 분석 단계 "안에서" 확률·분포·검정이 돌아간다.

1.3 검정은 분석 "안에" 들어 있는 추론 엔진

검정(t - F - χ^2)은 따로 노는 별개 분석이 아니라, 분석의 결과(p 값)를 만들어 내는 내부 부품입니다. 예를 들어 회귀계수 하나가 "진짜 0 이 아닌가"를 판단할 때 t 검정이 작동합니다. 그 작동 원리가 아래 그림입니다.




[그림 3] 계수를 표준오차로 나눈 t (검정통계량)를 t 분포에 대조해, 꼬리 넓이(p 값)로 판단한다.

한 줄 흐름: 계수(분석) → 계수÷표준오차 = t (검정) → t 분포 곡선(분포) → 꼬리 넓이 = p 값(확률).
회귀 요약표 한 화면에 이 네 층이 동시에 들어 있습니다.

1.4 사실은 한 몸 — t 검정 $\subset$ 분산분석 $\subset$ 회귀 $\subset$ 일반선형모형

가장 강력한 통합 관점입니다. 따로 배운 t 검정·분산분석·회귀는 별개 기법이 아니라 같은 선형 모형을 다른 각도에서 본 것입니다.




[그림 4] 안쪽은 바깥의 특수한 경우. 2 집단 t 검정 = 집단 2 개인 분산분석 = 범주형 1 개인 회귀.

- 2 표본 t 검정 = 집단이 2 개인 일원분산분석
- 일원분산분석 = 설명변수가 범주형 하나인 회귀분석
- 검정통계량도 연결됨: 자유도 1 인 $F = t^2$ (예: $t=2.6 \leftrightarrow F=6.76$)

1.5 데이터가 있을 때 — 어떤 분석을 고르나

학생들이 가장 어려워하는 "이 문제엔 무엇?"을 한 장으로 정리했습니다. 묻는 질문의 종류로 갈라집니다.



[그림 5] 질문 유형 → 분석 선택. 집단 평균 비교는 2 집단이면 t 검정, 3 집단 이상이면 분산분석.

이럴 때(질문)	데이터 형태	분석	주로 보는 값
두 변수가 같이 움직이나?	연속 × 연속	상관분석	r, p 값
Y를 X(들)로 설명·예측?	연속 Y, 연속/범주 X	회귀분석	coef, p, R ²
두 집단 평균이 다른가?	연속 Y, 2 집단	t 검정	t, p 값
세 집단+ 평균이 다른가?	연속 Y, 3 집단+	분산분석(ANOVA)	F, p 값
여러 요인·교호작용 효과?	연속 Y, 여러 요인	DOE ANOVA	F, p, 효과도
두 범주가 연관됐나?	범주 × 범주	카이제곱 검정	χ ² , p 값
단독으로 자주: 가정 점검	잔차 등	정규성·등분산 검정	p 값(>0.05 면 가정 OK)

[참고] "검정만 단독으로 쓸 일"도 분명히 있습니다

- ① 두 집단 비교·범주 연관 같은 단순 비교,
- ② 분석을 돌리기 전 정규성·등분산을 확인하는 가정 점검. 다만 대부분의 시간은 위 분석(회귀·분산·상관)을 해석하는 데 씁니다.

2. 분석 결과 해석 기준 — statsmodels 요약표 읽는 법

회귀분석을 돌리면 statsmodels 는 세 덩어리의 요약표를 줍니다.

① 상단(모형 전체) ② 가운데(계수별) ③ 하단(잔차 가정 점검).

분산분석은 별도의 ANOVA 표를 줍니다. 각 항목의 의미와 "값에 따른 해석"을 정리합니다.

가장 중요한 원칙: p 값 하나로 끝내지 말 것. "유의 한가(p)" + "얼마나 큰가(효과 크기)" + "가정이 맞나(잔차 진단)" 세 가지를 함께 봐야 옳은 해석입니다.

2.1 상단 — 모형 전체 평가

항목	의미	값에 따른 해석
R-squared (R^2)	반응의 변동 중 모형이 설명한 비율(0~1)	높을수록 설명력 ↑. 단 변수 늘면 무조건 증가. 분야별 기준 다름(공학 0.9 기대, 사회과학 0.3 도 의미)
Adj. R-squared	변수 개수를 보정한 R^2	R^2 와 크게 벌어지면 쓸모없는 변수가 많다는 신호. 변수 비교 시 이 값을 본다
F-statistic	모형 전체의 유의성 통계량	클수록 모형이 잡음 대비 의미 있음. 아래 Prob(F)로 판단
Prob (F-statistic)	모형 전체가 무의미하다는 가설의 p 값	< 0.05 → 적어도 한 변수는 유의(모형이 의미 있음). > 0.05 면 모형 자체가 무의미
No. Observations	표본 수 n	작으면(예: 변수당 10 개 미만) 결과 불안정·과적합 위험
Df Residuals / Df Model	잔차 자유도($n-p-1$) / 모형 자유도(설명변수 수)	잔차 자유도가 0 이면 오차 추정 불가(포화) → 유의성 판단 불가
AIC / BIC	모형 비교용 정보기준	단독 해석 X. 같은 데이터의 여러 모형 중 작을수록 좋음(BIC 가 더 엄격)
Cond. No.	설명변수 간 다중공선성·수치 안정성	> 30 주의, > 1000 심각(개별 계수 해석 위험). 설계 진단의 "조건수"와 동일 개념

2.2 가운데 — 계수표(변수별 효과)

항목	의미	값에 따른 해석
coef	회귀계수(기울기). X 1 단위 ↑ 시 Y 변화량	부호=방향(+증가/-감소), 크기=효과. 단위 의존이라 표준화 전엔 변수 간 직접 비교 금물
std err	계수 추정의 표준오차	작을수록 추정이 정밀. 표본 ↑·잡음 ↓일수록 작아짐
t	coef ÷ std err (검정통계량)	0 에서 표준오차 몇 배 떨어졌나. t 대략 2 이상이면 0.05 수준 유의(자유도 클 때)
P> t	그 계수가 0 이라는 가설의 p 값	< 0.05 유의, < 0.01 강하게, < 0.001 매우 강하게. > 0.05 면 "영향 있다"고 말 못 함
[0.025 0.975]	계수의 95% 신뢰구간	구간이 0 을 포함하면 유의하지 않음(P> t >0.05 와 일치). 좁을수록 추정 정밀

[해석 예]

coef=2.5, P>|t|=0.003, [1.1, 3.9] → "X 가 1 늘면 Y 가 평균 2.5 증가하며(방향·크기), 통계적으로 유의하고(p<0.01), 신뢰구간이 0 을 넘지 않아 효과가 0 일 가능성은 낮다."

2.3 하단 — 잔차 가정 점검(이게 맞아야 위 p 값을 믿는다)

항목	의미	값에 따른 해석
Omnibus / Prob(Omnibus)	잔차 정규성 종합검정	Prob(Omnibus) > 0.05 → 정규성 가정 OK(귀무가설=정규). < 0.05 면 정규성 위반 의심
Skew (왜도)	잔차 분포의 비대칭	0 이 이상적. Skew < 0.5 대체로 대칭, 0.5~1 중간, > 1 강한 치우침
Kurtosis (첨도)	꼬리의 두께	정규=3. > 3 뾰족·두꺼운 꼬리(이상치 의심), < 3 평평
Jarque-Bera / Prob(JB)	왜도+첨도 기반 정규성 검정	Prob(JB) > 0.05 → 정규성 OK. Omnibus 와 함께 본다
Durbin-Watson	잔차의 자기상관(이웃 잔차가 닮았나)	0~4, 2 근처가 이상적(무상관). < 1.5 양의 자기상관, > 2.5 음의 자기상관(시계열 데이터 주의)
Cond. No.	다중공선성(상단과 동일)	> 30 주의: 설명변수끼리 겹쳐 개별 계수 해석이 불안정

가정이 깨지면(정규성·등분산·독립성·선형성) 위의 p 값과 신뢰구간을 그대로 믿기 어렵습니다. 그래서 하단 진단을 먼저 확인하는 습관이 중요합니다.

2.4 분산분석(ANOVA) 표

항목	의미	값에 따른 해석
sum_sq (SS)	그 요인이 설명하는 변동량	클수록 그 요인이 반응 변동을 많이 설명
df	자유도	요인 수준 수-1 등. 잔차 df가 있어야 검정 가능
mean_sq (MS=SS/df)	평균제곱	F 계산의 재료
F	요인 MS ÷ 잔차 MS	클수록 요인 효과가 잡음 대비 큼
PR(>F) (p 값)	그 요인이 무의미하다는 가설의 p 값	< 0.05 → 그 요인이 반응에 유의한 영향
(참고) $\eta^2 = \text{SS 요인} / \text{SS 총}$	효과 크기(설명 비율)	p와 별개로 "실질적으로 큰가"를 본다(0.01 작음, 0.06 중간, 0.14 ↑ 큼)

2.5 해석할 때 흔한 함정 — 체크리스트

- 통계적 유의 ≠ 실질적 중요. 표본이 크면 사소한 차이도 $p < 0.05$ 가 된다 → 효과 크기(coef· R^2 · η^2)를 꼭 함께 본다.
- $p > 0.05$ 는 "효과 없음의 증명"이 아니라 "증거 부족"이다. "차이 없다"고 단정하지 말 것.
- R^2 가 높다고 인과관계는 아니다. 상관·예측력과 인과는 다르다.
- 다중공선성(Cond. No. ↑, VIF ↑)이 크면 개별 계수의 부호·크기 해석이 뒤집힐 수 있다.
- 여러 변수·여러 검정을 동시에 보면 우연히 유의한 게 나온다 → 다중비교 보정 고려.
- 잔차 가정(정규성·등분산·독립성)을 먼저 확인하고 나서 p 값을 믿어라.